本研究就中國現代文學根本性的敘事主題“鄉村敘事”和“城市敘事”的二元對立作為分類實驗，我選取了沈從文的《邊城》和老舍的《駱駝祥子》作為文本分析。沈從文的《邊城》圍繞著茶峒的渡口，溪水與白塔，構造出一個與大自然與人情往來為錨點的鄉土空間。而老舍的《駱駝祥子》則以北平的胡同，車廠與街道作為敘事背景，塑造一個獎社會底層人物剝奪吞噬的城市空間。兩者之間的差異，究竟是主題內容的差異，還是文體形式的差異？一個僅依賴詞彙表層特徵的詞袋模型，能否在段落級別上捕捉到這種差異？這是本報告試圖回答的問題。本實驗以《邊城》和《駱駝祥子》為語料，訓練一個 Logistic Regression 分類器，並在測試集上檢驗：一個極簡的線性模型，究竟能在多大程度上「學會」城鄉敘事的區分。

數據處理方式

標籤定義為兩個互斥類別：鄉村敘事（label=0）與城市敘事（label=1）。鄉村敘事的操作性標準是：段落的敘事空間以渡口、溪流、田野、山坳或村落為核心錨點，人物關係圍繞宗族、鄰里或船總與水手等鄉土共同體組織，衝突落點在於土地、收成或傳統禮俗。城市敘事的標準則是：空間以街道、胡同、車廠、商鋪或巡警局為核心，關係圍繞契約僱傭、主顧交易或陌生人互動展開，衝突落點在於金錢、職業流動或制度規訓。

文本單位選定為自然段落，長度限制在 60 至 450 字之間。短於 60 字的段落往往只包含孤立的景物描寫或動作片段，缺乏足夠的關係信息來判斷敘事空間；長於 450 字的段落則可能在一段之內完成從鄉村到城市的場景切換（例如《駱駝祥子》中祥子回憶鄉下的閃回），導致標籤失真。最終從兩部小說中提取並平衡了約 300 個段落（具體數量以倉庫 data/labeled.csv 為準），按 8:2 的比例進行分層切分（stratify=label，random state=42），保證訓練集與測試集的類別比例一致。

標註採用弱監督方式：對每個段落用 jieba 分詞，分別統計鄉村詞表（如「渡口」「溪」「白塔」「船總」「祖父」）與城市詞表（如「洋車」「胡同」「車廠」「巡警」「掌柜」）的命中詞數。鄉村得分高於城市則標為 0，反之標為 1。然而這樣的設計雖然可以覆蓋較大的詞語和較寬的文本範圍，但詞表覆蓋有限，倒敘、閃回與城鄉混合場景容易產生系統性誤標。

特徵與分類器

實驗比較了三種特徵方案，均搭配 LogisticRegression（solver="liblinear"，

class weight="balanced"，max_iter=3000）：

詞頻 top-200：Count Vectorizer，僅保留最高頻的 200 個詞。這是最樸素的基線，用於檢驗高頻詞本身是否攜帶城鄉信號。

詞級 TF-IDF（1,2）：T F- IDF Vectorizer，unigram 與 bigram，sublinear=True。TF-IDF 抑制了“的”“了”“是”等功能詞的主導地位，使“渡口”“洋車”“胡同”“溪邊”等空間標記詞的權重得以凸顯。

字符級 TF-IDF（2,3）：analyzer="char-wb"，字符 2 至 3-gram。中文不需要預先分詞，字符 n-gram 可以直接捕獲空間標記詞的詞形，避免 jieba 將“渡口”切分為“渡/口”所造成的資訊損失。

未採用 z-score 方案，原因是 TF-IDF 向量本身已經稀疏，每一維已經是“詞頻x逆文檔頻率”的標準化形式；對每一維再做 z-score 會破壞稀疏結構，且不會帶來額外的判別資訊。

測試結果

在測試集上，字符級 TF-IDF 取得了最高的 Macro-F1，準確率也高於詞級 TF-IDF 與詞頻基線（具體數值以 output/metrics.json 為準）。詞頻 top-200 的表現最弱，這符合預期：最高頻詞往往被“的”“了”“他”“是”等功能詞佔據，城鄉空間標記詞很難進入前 200。

混淆矩陣揭示了一個值得注意的不對稱模式。城市段落被誤判為鄉村的比例，往往高於鄉村段落被誤判為城市的比例。這一模式的根源可以在文本中找到解釋。《駱駝祥子》中存在大量祥子回憶鄉下或初入城市時的閃回段落：這些段落的敘述主體是城市人物，但空間詞彙卻指向田野、村莊或“鄉下”。例如，當祥子想起“鄉下的那幾畝地”或“在鄉下的時候”時，弱監督詞表會命中鄉村空間詞，從而給出“鄉村”標籤——儘管這段文字在整部小說中的敘事功能是城市異化敘事的一部分。這正是“鄉下人進城”敘事所固有的空間混雜性：人物的身體在城市中移動，記憶卻不斷回返鄉村。

鄉村段落被誤判為城市的比例相對較低，但並非為零。《邊城》中少數提及「城裡」「商人」「船總生意」的段落，可能在關係詞上更接近城市建制。不過，由於《邊城》的整體抒情語調與感官化的景物描寫極為突出，字符級特徵仍然能夠將這些段落拉回「鄉村」一側。

局限與改良空間

本實驗最根本的限制在於作者風格與類別標籤的完全共線。語料只有兩部小說，兩部小說各由一位作者所寫，標籤的差異（鄉村/城市）與作者的差異（沈從文/老舍）在統計上無法分離。模型達到的高準確率，既可以解釋為「學會了城鄉敘事」，也可以解釋為「學會了沈從文文體與老舍文體的區分」。後者甚至可能是更簡潔的解釋：沈從文的抒情短句、方言詞彙與感官化描寫，老舍的京味口語、市井對話與密集的動詞序列，本身就已經是極強的分類信號，根本不需要「城鄉」這個中間概念。

其次是弱監督標註的噪聲。詞表只能覆蓋顯性的空間與關係詞，無法處理反諷、隱喻或隱含的空間指涉。《駱駝祥子》中祥子對鄉村的回憶之所以被誤標，正是因為詞表看到了「鄉下」這個詞，卻沒有能力判斷這句話在敘事功能上屬於城市經驗的一部分。

第三是段落邊界的主觀性。60 至 450 字的選擇是一種權衡，但段落本身是編輯與排版的產物，未必對應敘事空間的自然轉換單位。

改進的方向是明確的：引入同一作者內部的城鄉對照片段，將作者風格從標籤中解耦。例如，《駱駝祥子》中祥子對鄉下的回憶段落，可以與同一部小說中純粹的城市街道描寫形成對照；《邊城》中提及「城裡」的段落，也可以與渡口段落形成對照。如果模型在同一作者的文本內部仍能區分城鄉敘事，那麼「文體差異」的解釋才會獲得更有力的支持。此外，擴大語料至每位作者的多部作品、採用主動學習減少人工校正成本，以及將段落單位與敘事學上的「場景」單位對齊，都是值得嘗試的方向。